

NAND MoE Simulator 使用说明

软件简介

NAND MoE Simulator 是一个用于模拟 NAND Flash 存储专家混合模型（Mixture of Experts, MoE）参数的仿真工具。支持三种不同的数据布局模式，并可分析预取策略对性能的影响。

系统要求

- Windows 10/11 操作系统
 - 无需安装 Python，双击即可运行
 - 建议屏幕分辨率 1920×1080 或以上以获得最佳体验
-

使用方法

启动软件

双击 `NAND\_MoE\_Simulator.exe` 启动程序。

界面说明

软件包含两个标签页：

1. 主模拟

用于模拟指定 Expert 集合的读取延迟和带宽利用率。

操作步骤：

1. 在左侧面板配置硬件参数和 MoE 模型参数
2. 在"专家命中配置"区域输入要读取的 Expert IDs（支持格式：`0, 1, 2` 或 `0-9` 或 `0-3, 5, 7-9`）
3. 选择布局模式（跳跃SLC、默认SLC、TLC）
4. 勾选预取选项
5. 点击"运行模拟"按钮
6. 查看右侧输出区域的模拟结果

2. 专家命中仿真

用于通过蒙特卡洛模拟分析不同访问模式和预取策略的性能对比。

操作步骤：

1. 配置硬件参数和 MoE 模型参数
 2. 设置 TopK（每次选择的 Expert 数量）
 3. 选择布局模式
 4. 设置仿真次数（默认为 50 次）
 5. 点击"运行专家命中仿真"按钮
 6. 查看对比结果表格和图表
-

参数说明

硬件性能参数

参数	说明	默认值
单通道带宽	单个 NAND 通道的带宽, 单位 GB/	3.75
tR 读取延迟	读取一个 Page 的延迟, 单位 μs	22.0

NAND 几何参数

参数	说明	默认值
通道数	NAND 通道数量	8
每通道 Plane 数	每个通道包含的 Plane 数量	8
Page 大小	每页大小, 单位 KB	16

MoE 模型参数

参数	说明	默认值
Expert 总数	MoE 模型中的专家总数	512
Gate 参数大小	Gate 层参数字节数	294912
Up 参数大小	Up 投影层参数字节数	294912
Down 参数大小	Down 投影层参数字节数	694912

专家命中配置

参数	说明	默认值
TopK	每次选择的 Expert 数量	10
Expert IDs	要读取的专家 ID 列表	0, 1, 2, 3, 4, 5, 6, 7, 8, 9

Expert IDs 输入格式:

- 离散格式: `0, 1, 2, 3, 4`
- 连续格式: `0-9` (表示 0 到 9)
- 混合格式: `0-3, 5, 7-9` (表示 0, 1, 2, 3, 5, 7, 8, 9)

布局模式说明

跳跃 SLC (CH-first)

- **原理**: 数据按 Channel 轮询分布, 先填满所有 Channel 的第 0 个 Plane, 再填第 1 个 Plane
- **特点**: 跨通道交错存储, 随机访问性能好
- **预取效果**: 专家内预取和专家间预取效果较差

默认 SLC (PL-first)

- **原理**: 数据先填满一个 Channel 的所有 Planes, 再切换到下一个 Channel
- **特点**: 同一 Channel 内 Plane 连续存储
- **预取效果**: 专家内预取效果好, 专家间预取效果一般

TLC

- **原理**: Channel 内按 Page 优先填充, 每 3 个 Page 为一组跨 Channel 填充
- **特点**: 最大化同一 Expert 的参数在物理存储上的连续性

- ****预取效果****: 专家内预取效果最好, 能最大化利用 TLC 的读取特性
-

预取选项

- ****启用专家内预取****: 预取同一 Expert 的 Gate/Up/Down 参数
- ****启用专家间预取****: 预取相邻 Expert 的参数

同时启用两种预取可获得最佳性能。

图表操作

布局图

- ****滚轮缩放****: 在图表区域滚动鼠标滚轮可放大/缩小
- ****平移****: 使用工具栏的手形工具可拖动图表

专家命中仿真结果图

- 包含 4 个子图: 总延迟、有效带宽、时间分解、预取节省量
 - 同样支持滚轮缩放
-

注意事项

1. ****多次运行****: 支持多次运行模拟, 但每次需等待前一次完成
 2. ****图表窗口****: 图表窗口可打开多个, 使用完毕后请手动关闭
 3. ****参数范围****: Expert IDs 输入值应在 0 到 Expert 总数-1 之间
 4. ****仿真时间****: 专家命中仿真需要运行多次蒙特卡洛试验, 根据仿真次数可能需要几秒钟到几十秒不等
-

技术细节

- 核心算法基于 NAND Flash 的并行读取特性建模
- 带宽计算考虑通道级并行和预取优化
- 延迟模型包含 t_R 读取延迟和数据传输时间